

Selección de Modelos Lineales y Regularización

Big Data y Machine Learning para Economía Aplicada

Ignacio Sarmiento-Barbieri

Universidad de los Andes

Agenda

- 1 Previously...
- 2 Selección de Modelos Lineales
- 3 Regularización
 - Recap: OLS Mechanics
 - Ridge
 - Implementación

Agenda

- 1 Previously...
- 2 Selección de Modelos Lineales
- 3 Regularización
 - Recap: OLS Mechanics
 - Ridge
 - Implementación

El objetivo

- ▶ Para cualquier variable aleatoria Y y vector de covariables W , tenemos:

$$y = m(W) + u$$

- ▶ Bajo pérdida cuadrática, para cualquier función medible $m(W)$:

$$\mathbb{E}[Y | W] = \arg \min_m \mathbb{E}[(Y - m(W))^2]$$

- ▶ La CEF es el objetivo, pero:
 - ▶ No observamos W directamente: observamos X (aproximación ruidosa).
 - ▶ Desconocemos la forma funcional de $m(W)$.

Restringiendo a la clase lineal: el BLP

- Supongamos que *conocemos* W . Buscamos el mejor predictor **lineal**:

$$\beta^* = \arg \min_{\beta} \mathbb{E}[(Y - W'\beta)^2]$$

- **Condición de primer orden** (diferenciando e igualando a cero):

$$\mathbb{E}[W(Y - W'\beta)] = 0 \implies \boxed{\beta^* = [\mathbb{E}(WW')]^{-1} \mathbb{E}(WY)}$$

- El **Best Linear Predictor** es $W'\beta^*$.
- $\text{BLP} \neq \text{CEF}$ en general: $W'\beta^* = \mathbb{E}[Y | W]$ solo si $\mathbb{E}[Y | W]$ es lineal en W

Restringiendo a la clase lineal: el BLP

La descomposición con el BLP

- ▶ Partiendo de $Y = m(W) + u$ (con $\mathbb{E}[u | W] = 0$ y $V[u | W] = \sigma^2$):

$$Y = \underbrace{W' \beta^*}_{\text{BLP}} + \underbrace{(\mathbb{E}[Y | W] - W' \beta^*)}_{\eta: \text{error de no-linealidad}} + \underbrace{u}_{\text{irreducible}}$$

- ▶ η no desaparece a menos que $m(W)$ sea exactamente lineal.
- ▶ El BLP minimiza el MSE dentro de la clase lineal, *no* globalmente.

Dos problemas, una estrategia

- ▶ En la práctica enfrentamos simultáneamente:

- 1 No observamos W , solo X , subconjunto o versión ruidosa de W .
- 2 $\mathbb{E}[Y \mid W]$ probablemente no es lineal en W .

- ▶ **Estrategia:** construir un **diccionario de predictores**

$$g(X) = (g_1(X), g_2(X), \dots, g_p(X))'$$

donde cada g_j es una transformación de X : polinomios, interacciones $X_i X_j$, etc.

- ▶ La linealidad en β **no** es una restricción sobre la forma funcional es una restricción sobre cómo combinamos un diccionario que *nosotros elegimos*.
- ▶ Con $g(X)$ suficientemente rico, podemos aproximar cualquier $\mathbb{E}[Y \mid W]$ suave.

Restringiendo a la clase lineal: el BLP

La descomposición completa de errores

- El BLP de Y sobre $g(X)$ es $g(X)' \beta^*$ con $\beta^* = [\mathbb{E}(g(X)g(X)')]^{-1} \mathbb{E}(g(X)Y)$.

$$Y = \underbrace{g(X)' \beta^*}_{\text{BLP aprox.}} + \underbrace{(\mathbb{E}[Y | W] - g(X)' \beta^*)}_{\eta: \text{error de especificación}} + \underbrace{u}_{\text{irreducible}}$$

- Mapa completo del problema (teórico)

$$\underbrace{\mathbb{E}[Y | W]}_{\text{CEF}} \xrightarrow{\text{linealizar}} \underbrace{W' \beta^*}_{\text{BLP en } W} \xrightarrow{W \rightarrow g(X)} \underbrace{g(X)' \beta^*}_{\text{BLP aprox.}} \xrightarrow{\text{estimar}} \underbrace{g(X)' \hat{\beta}}_{\text{predictor}}$$


Error de predicción fuera de muestra

- ▶ ML nos interesa la predicción fuera de muestra
- ▶ Para un nuevo punto x^* , el error cuadrático esperado es:

$$\underbrace{\mathbb{E}[(Y^* - g(x^*)'\hat{\beta})^2]}_{\text{Error de Predicción Esperado}} = \underbrace{\sigma_u^2}_{\text{irreducible}} + \underbrace{(\mathbb{E}[Y^* | W^*] - g(x^*)'\beta^*)^2}_{\text{Sesgo}^2} + \underbrace{\mathbb{E}[(g(x^*)'\hat{\beta} - g(x^*)'\beta^*)^2]}_{\text{Varianza}}$$

- ▶ Overfit: modelos complejos predicen muy bien dentro de muestra, pero tienden a hacer un mal trabajo fuera de muestra

Error de predicción fuera de muestra



Error de predicción fuera de muestra

- ▶ En el modelo lineal, la diferencia entre los dos errores:

Agenda

① Previously...

② Selección de Modelos Lineales

③ Regularización

- Recap: OLS Mechanics
- Ridge
- Implementación

Model Subset Selection

- ▶ Tenemos un diccionario con p predictores: $g_1(X), \dots, g_p(X)$
- ▶ Cada subconjunto de predictores define un modelo $\Rightarrow$ hay 2^p modelos posibles
- ▶ Objetivo: encontrar el que mejor predice **fuera de muestra**
- ▶ **Best Subset Selection:**
 - ▶ Para cada tamaño $k = 0, 1, \dots, p$: ajustar *todos* los $\binom{p}{k}$ modelos con k predictores
 - ▶ Guardar el mejor de cada tamaño (menor MSE dentro de muestra): $\mathcal{M}_0, \mathcal{M}_1, \dots, \mathcal{M}_p$
 - ▶ Elegir entre $\mathcal{M}_0, \dots, \mathcal{M}_p$

Cuántos modelos hay que ajustar

p	Mejor conjunto 2^p
3	8
10	1.024
20	1.048.576
40	1.099.511.627.776

Stepwise Selection

- ▶ Cuando 2^p es infactible: búsqueda *greedy* en vez de exhaustiva
- ▶ **Forward selection:** empezar sin predictores; en cada paso agregar el que más reduce el error dentro de muestra
- ▶ **Backward selection:** empezar con los p predictores; en cada paso quitar el que menos aporta

Stepwise Selection

- ▶ Cuando 2^p es infactible: búsqueda *greedy* en vez de exhaustiva
- ▶ **Forward selection:** empezar sin predictores; en cada paso agregar el que más reduce el error dentro de muestra
- ▶ **Backward selection:** empezar con los p predictores; en cada paso quitar el que menos aporta
- ▶ El precio: no garantizan encontrar el mejor subconjunto (las decisiones tempranas persisten)

Elección por pasos

Los dos algoritmos


1 Hacia adelante (*forward*)

- ▶ Empezar sin predictores
- ▶ Probar todos los modelos con 1 predictor y quedarse con el mejor (medido con RSS)
- ▶ Agregar de a un predictor por vez, sin sacar ninguno
- ▶ De los $p + 1$ modelos, elegir el de menor error de predicción con validación cruzada

2 Hacia atrás (*backward*)

- ▶ La misma idea, pero arrancando del modelo completo y sacando de a uno


Hacia adelante



★ el mejor par de los tres. *Forward* nunca lo ajusta.

- Una vez que entra x_3 , el par $\{x_1, x_2\}$ es **inalcanzable**

Hacia atrás



★ el mismo par de la slide anterior.

- Acá sí pasa por $\{x_1, x_2\}$: desde el modelo completo mira los tres pares

Cuántos modelos hay que ajustar

p	Mejor conjunto 2^p	Por pasos $1 + p(p + 1)/2$
3	8	7
10	1.024	56
20	1.048.576	211
40	1.099.511.627.776	821

Comparación

- ▶ Se pasa de 2^p modelos a $1 + p(p + 1)/2$
- ▶ Ninguno de los dos garantiza encontrar el mejor de los 2^p
- ▶ *Forward*: una columna que entró, no sale
- ▶ *Backward*: una columna que salió, no vuelve. Y exige $n > p$ para poder ajustar el modelo completo
- ▶ *Forward* corre con $n < p$
- ▶ El anidamiento es lo que los hace “factibles”, y es lo que los hace fallar

¿Cómo elegir entre $\mathcal{M}_0, \mathcal{M}_1, \dots, \mathcal{M}_p$?

- ▶ El error dentro de muestra mejora *siempre* al agregar predictores $\Rightarrow$ elegiríamos $\mathcal{M}_p$
- ▶ Pero ya sabemos que el error dentro de muestra es optimista:

$$\text{MSE}_{\text{fuera}} = \text{MSE}_{\text{dentro}} + \underbrace{2 \cdot \frac{p}{N} \cdot \sigma_u^2}_{\text{"optimismo"}}$$

- ▶ Dos estrategias para comparar modelos de distinto tamaño:
 - ▶ **Corregir** el optimismo con una penalización analítica: C_p , AIC, BIC, R^2 ajustado
 - ▶ **Estimarlo** directamente con validación cruzada
- ▶ En ML el estándar es CV: no requiere supuestos, y cuando p/N no es pequeño la aproximación de AIC, BIC, etc. se rompe

De la selección discreta al shrinkage

- ▶ Best subset equivale a penalizar el *número* de predictores:

$$\min_{\beta} \sum_{i=1}^n (y_i - x_i' \beta)^2 + \lambda \|\beta\|_0, \quad \|\beta\|_0 = \#\{j : \beta_j \neq 0\}$$

- ▶ Dos problemas:
 - ▶ **Computacional:** $\|\beta\|_0$ no es convexa $\Rightarrow$ hay que buscar sobre los 2^p subconjuntos
 - ▶ **Estadístico:** la selección es discreta (un predictor está o no está); pequeños cambios en los datos cambian el subconjunto elegido $\Rightarrow$ alta varianza
- ▶ **Idea:** reemplazar $\|\beta\|_0$ por una penalización continua que *encoja* los coeficientes en vez de eliminarlos de golpe
- ▶ Eso es **regularización** $\rightarrow$ empezamos con Ridge

Agenda

- 1 Previously...
- 2 Selección de Modelos Lineales
- 3 Regularización
 - Recap: OLS Mechanics
 - Ridge
 - Implementación

Agenda

- 1 Previously...
- 2 Selección de Modelos Lineales
- 3 Regularización
 - Recap: OLS Mechanics
 - Ridge
 - Implementación


Regularización: Motivación

- OLS minimiza el error “*dentro de muestra*”, eligiendo β de forma tal que

$$\min_{\beta} L(\beta) = \sum_{i=1}^n (y_i - \beta_0 - x_{i1}\beta_1 - \cdots - x_{ip}\beta_p)^2$$

OLS 1 Dimensión


$$\min_{\beta} L(\beta) = \sum_{i=1}^n (y_i - x_i \beta)^2$$



App

OLS 2 Dimensiones

$$\min_{\beta} L(\beta) = \sum_{i=1}^n (y_i - x_{i1}\beta_1 - x_{i2}\beta_2)^2$$



Fuente: <https://allmodelsarewrong.github.io>

Regularización: Motivación

- ▶ OLS minimiza el error “*dentro de muestra*”, eligiendo β de forma tal que

$$\min_{\beta} L(\beta) = \sum_{i=1}^n (y_i - \beta_0 - x_{i1}\beta_1 - \cdots - x_{ip}\beta_p)^2$$

- ▶ pero para predicción, no estamos interesados en hacer un buen trabajo dentro de muestra
- ▶ Queremos hacer un buen trabajo, **fuera de muestra**

Agenda

- 1 Previously...
- 2 Selección de Modelos Lineales
- 3 Regularización
 - Recap: OLS Mechanics
 - Ridge
 - Implementación

Penalizamos lo que crea varianza

- ▶ Asegurar cero sesgo dentro de muestra crea problemas fuera de muestra: trade-off Sesgo-Varianza
- ▶ Las técnicas de machine learning fueron desarrolladas para hacer este trade-off de forma empírica.
- ▶ Vamos a proponer modelos del estilo

$$\min_{\beta} L(\beta) = \sum_{i=1}^n (y_i - \beta_0 - x_{i1}\beta_1 - \cdots - x_{ip}\beta_p)^2 + \lambda \sum_{j=1}^p R(\beta_j)$$

- ▶ donde R es un regularizador que penaliza funciones que crean varianza

Ridge

- Para un $\lambda \geq 0$ dado, consideremos ahora el siguiente problema de optimización

$$\min_{\beta} L(\beta) = \sum_{i=1}^n (y_i - \beta_0 - x_{i1}\beta_1 - \cdots - x_{ip}\beta_p)^2 + \lambda \sum_{j=1}^p (\beta_j)^2$$

Ridge: Intuición en 1 Dimensión

- ▶ 1 predictor centrado y normalizado a norma euclídea 1
- ▶ El problema:

$$\min_{\beta} L(\beta) = \sum_{i=1}^n (y_i - x_i \beta)^2 + \lambda \beta^2$$

- ▶ La solución?

Ridge: Intuición en 1 Dimensión

Problema como optimización restringida

- Existe un $c > 0$ tal que $\hat{\beta}(\lambda)$ es la solución a

$$\min_{\beta} L(\beta) = \sum_{i=1}^n (y_i - x_i \beta)^2$$

sujeto a

$$(\beta)^2 \leq c$$

Ridge: Intuición en 1 Dimensión

Problema como optimización restringida

Ridge: Intuición en 2 Dimensiones

- Al problema en 2 dimensiones podemos escribirlo como

$$\min_{\beta} L(\beta) = \sum_{i=1}^n (y_i - x_{i1}\beta_1 - x_{i2}\beta_2)^2 + \lambda (\beta_1^2 + \beta_2^2)$$

- podemos escribirlo como un problema de optimización restringido


$$\min_{\beta} L(\beta) = \sum_{i=1}^n (y_i - x_{i1}\beta_1 - x_{i2}\beta_2)^2$$

sujeto a

$$((\beta_1)^2 + (\beta_2)^2) \leq c$$

Ridge: Intuición en 2 Dimensiones


$$\min_{\beta} L(\beta) = \sum_{i=1}^n (y_i - x_{i1}\beta_1 - x_{i2}\beta_2)^2 \text{ s.a. } ((\beta_1)^2 + (\beta_2)^2) \leq c$$



Fuente: <https://allmodelsarewrong.github.io>

Ridge: Intuición en 2 Dimensiones


$$\min_{\beta} L(\beta) = \sum_{i=1}^n (y_i - x_{i1}\beta_1 - x_{i2}\beta_2)^2 \text{ s.a. } ((\beta_1)^2 + (\beta_2)^2) \leq c$$



Fuente: <https://allmodelsarewrong.github.io>

Ridge: Intuición en 2 Dimensiones


$$\min_{\beta} L(\beta) = \sum_{i=1}^n (y_i - x_{i1}\beta_1 - x_{i2}\beta_2)^2 \text{ s.a. } ((\beta_1)^2 + (\beta_2)^2) \leq c$$



Fuente: <https://allmodelsarewrong.github.io>

Ridge: Intuición en 2 Dimensiones

$$\min_{\beta} L(\beta) = \sum_{i=1}^n (y_i - x_{i1}\beta_1 - x_{i2}\beta_2)^2 \text{ s.a. } ((\beta_1)^2 + (\beta_2)^2) \leq c$$



Fuente: <https://allmodelsarewrong.github.io>

Ridge tiene forma cerrada

- ▶ En regresión múltiple (X es una matriz $n \times p$)
- ▶ Regresión: $y = X\beta + \varepsilon$
- ▶ OLS

$$\hat{\beta}_{ols} = (X'X)^{-1}X'y$$

- ▶ Ridge

$$\hat{\beta}_{ridge} = (X'X + \lambda I)^{-1}X'y$$

Nota: la expresión de ridge supone X centrada y *sin* intercepto

Ridge cambia sesgo por varianza

- ▶ Ridge es sesgado $\mathbb{E}(\hat{\beta}_{ridge}) \neq \beta$

Ridge cambia sesgo por varianza

- ▶ Ridge es sesgado $\mathbb{E}(\hat{\beta}_{ridge}) \neq \beta$
- ▶ Pero la varianza es menor que la de OLS

Ridge cambia sesgo por varianza

- ▶ Ridge es sesgado $\mathbb{E}(\hat{\beta}_{ridge}) \neq \beta$
- ▶ Pero la varianza es menor que la de OLS
- ▶ Para ciertos valores del parámetro $\lambda \Rightarrow MSE_{OLS} > MSE_{ridge}$

Agenda

- 1 Previously...
- 2 Selección de Modelos Lineales
- 3 Regularización
 - Recap: OLS Mechanics
 - Ridge
 - Implementación

En Ridge la escala importa; en OLS no

- ▶ La escala de las variables importa en Ridge, mientras que en OLS no.
- ▶ Es importante estandarizar las variables X :

$$X^{std} = \frac{X - \mu_X}{\sigma_X}$$

Selección de λ

- ▶ Asegurar cero sesgo dentro de muestra crea problemas fuera de muestra: trade-off Sesgo-Varianza
- ▶ Ridge hace este trade-off de forma empírica.

$$\min_{\beta} L(\beta) = \sum_{i=1}^n (y_i - \beta_0 - x_{i1}\beta_1 - \cdots - x_{ip}\beta_p)^2 + \lambda \sum_{j=1}^p R(\beta_j)$$

- ▶ λ es el precio al que hacemos este trade off
- ▶ Como elegimos λ ?

Selección de λ (K-fold CV)

- ▶ Primero separamos la muestra en **entrenamiento** y **prueba** (*test*). El test se guarda y no se toca hasta la evaluación final
- ▶ λ es un hiperparámetro: lo elegimos por validación cruzada *dentro* de la muestra de entrenamiento
- ▶ Partimos la muestra de entrenamiento en K folds de tamaño similar (en la práctica, $K = 5$ o 10)
- ▶ Cada fold $k = 1, \dots, K$ juega una vez el rol de muestra de validación:
 - ▶ entrenamos con los otros $K - 1$ folds
 - ▶ evaluamos en el fold k
- ▶ Así, cada observación se usa para entrenar y (una sola vez) para validar

Selección de λ (Algoritmo)

- ▶ Para cada λ en una grilla $\{\lambda_1, \dots, \lambda_L\}$ y cada fold $k = 1, \dots, K$:
 - ▶ Ajustar Ridge *sin* el fold $k \rightarrow \hat{\beta}_{-k}(\lambda)$
 - ▶ Evaluar en las n_k observaciones del fold k (no usadas para entrenar):

$$\text{MSE}_k(\lambda) = \frac{1}{n_k} \sum_{i \in \text{fold } k} (y_i - x_i' \hat{\beta}_{-k}(\lambda))^2$$

- ▶ Promediar sobre los folds y elegir el mejor λ :

$$\text{CV}(\lambda) = \frac{1}{K} \sum_{k=1}^K \text{MSE}_k(\lambda), \quad \lambda^* = \arg \min_{\lambda} \text{CV}(\lambda)$$

- ▶ Con λ^* elegido, re-estimamos $\hat{\beta}_{\text{ridge}}(\lambda^*)$ con *toda* la muestra de entrenamiento
- ▶ Recién ahí evaluamos, **una sola vez**, en la muestra de prueba

Example



photo from <https://www.dailydot.com/parsec/batman-1966-labels-tumblr-twitter-vine/>

Review

$$\underbrace{\mathbb{E}[Y | W]}_{\text{CEF (objetivo)}} \xrightarrow{\text{linealizar}} \underbrace{W' \beta^*}_{\text{BLP}} \xrightarrow{W \rightarrow g(X)} \underbrace{g(X)' \beta^*}_{\text{BLP aprox.}} \xrightarrow{\text{estimar}} \underbrace{g(X)' \hat{\beta}}_{\text{predictor}}$$

► Error de Predicción Esperado (MSE)

$$\text{MSE} = \sigma_u^2 + \text{Sesgo}^2 + \text{Varianza}$$

- **Sesgo**²: propiedad del *modelo* $g(X)$. Baja al enriquecer $g(X)$. No depende de N .
- **Varianza**: propiedad del *estimador*. Para OLS: $\sigma_u^2 \cdot p/N$. Sube con p .

► Dentro vs. fuera de muestra

$$\text{MSE}_{\text{fuera}} = \text{MSE}_{\text{dentro}} + \underbrace{2 \frac{p}{N} \sigma_u^2}_{\text{"optimismo"}}$$

► Regularización: Ridge penaliza $\|\beta\|^2$ con parámetro λ :

- Introduce sesgo deliberadamente.
- Reduce varianza
- λ se elige por validación cruzada.