

Regularización: Lasso y Elastic Net

Big Data y Machine Learning para Economía Aplicada

Ignacio Sarmiento-Barbieri

Universidad de los Andes

Agenda

1 Regularization

- Recap
- Lasso
- Ridge and Lasso: Pros and Cons
- Familia de regresiones penalizadas
- Elastic Net

El problema

- ▶ El problema es de **predicción**: queremos que $\hat{y}$ funcione bien *fuera* de muestra, no que $\hat{\beta}$ sea insesgado.
- ▶ Y ahí el error se descompone:

$$\mathbb{E} [(Y - \hat{Y})^2] = \text{Sesgo}^2 + \text{Varianza} + \sigma_u^2 \quad (1)$$

Regularización: Motivación

- ▶ Las técnicas econométricas estándar no están optimizadas para la predicción porque se enfocan en la insesgadez.
- ▶ OLS por ejemplo es el mejor estimador lineal *insesgado*
- ▶ OLS minimiza el error “*dentro de muestra*”, eligiendo β de forma tal que

$$\min_{\beta} E(\beta) = \sum_{i=1}^n (y_i - \beta_0 - x_{i1}\beta_1 - \cdots - x_{ip}\beta_p)^2 \quad (2)$$

- ▶ pero para predicción, no estamos interesados en hacer un buen trabajo dentro de muestra
- ▶ Queremos hacer un buen trabajo, **fuera de muestra**

Ridge

- ▶ Asegurar cero sesgo dentro de muestra crea problemas fuera de muestra: trade-off Sesgo-Varianza
- ▶ Las técnicas de machine learning fueron desarrolladas para hacer este trade-off de forma empírica.
- ▶ Vamos a proponer modelos del estilo

$$\min_{\beta} E(\beta) = \sum_{i=1}^n (y_i - \beta_0 - x_{i1}\beta_1 - \cdots - x_{ip}\beta_p)^2 + \lambda \sum_{j=1}^p R(\beta_j) \quad (3)$$

- ▶ donde R es un regularizador que penaliza funciones que crean varianza


Ridge

- Para un $\lambda \geq 0$ dado, consideremos ahora el siguiente problema de optimización

$$\min_{\beta} E(\beta) = \sum_{i=1}^n (y_i - \beta_0 - x_{i1}\beta_1 - \cdots - x_{ip}\beta_p)^2 + \lambda \sum_{j=1}^p (\beta_j)^2 \quad (4)$$

Intuición en 2 Dimensiones (Ridge)

$$\min_{\beta} E(\beta) = \sum_{i=1}^n (y_i - x_{i1}\beta_1 - x_{i2}\beta_2)^2 \text{ s.a. } ((\beta_1)^2 + (\beta_2)^2) \leq c \quad (5)$$



Ridge as Data Augmentation (2)

RidgeDataAug

Añadimos p observaciones ficticias:

$$X_a = \begin{pmatrix} X \\ \sqrt{\lambda} I_p \end{pmatrix}_{(n+p) \times p}, \quad y_a = \begin{pmatrix} y \\ 0_p \end{pmatrix}$$

Corriendo OLS sobre esos datos aumentados:

$$X_a' X_a = X' X + \lambda I,$$

$$X_a' y_a = X' y$$

$$\hat{\beta}_a = \hat{\beta}_{ridge}$$

- **Ridge es OLS** sobre una muestra con p puntos inventados que dicen “ β_j debería ser 0”.

Lasso

- Para un $\lambda \geq 0$ dado, consideremos el siguiente problema de optimización

$$\min_{\beta} E(\beta) = \sum_{i=1}^n (y_i - \beta_0 - x_{i1}\beta_1 - \cdots - x_{ip}\beta_p)^2 + \lambda \sum_{j=1}^p |\beta_j| \quad (6)$$

Lasso

- ▶ Para un $\lambda \geq 0$ dado, consideremos el siguiente problema de optimización

$$\min_{\beta} E(\beta) = \sum_{i=1}^n (y_i - \beta_0 - x_{i1}\beta_1 - \cdots - x_{ip}\beta_p)^2 + \lambda \sum_{j=1}^p |\beta_j| \quad (6)$$

- ▶ “LASSO’s free lunch”: selecciona automáticamente los predictores que van en el modelo ($\beta_j \neq 0$) y los que no ($\beta_j = 0$)
- ▶ Por qué? Los coeficientes que no van son soluciones de esquina
- ▶ $L(\beta)$ es no differentiable

Lasso

Intuición

$$\min_{\beta} E(\beta) = \underbrace{\sum_{i=1}^n \left(y_i - \beta_0 - \sum_{j=1}^p x_{ij} \beta_j \right)^2}_{\text{SSR}(\beta)} + \lambda \sum_{j=1}^p |\beta_j|$$

Y su forma restringida:


$$\min_{\beta} \text{SSR}(\beta) \quad \text{sujeto a} \quad \sum_{j=1}^p |\beta_j| \leq c$$

$$\min_{\beta} \text{SSR}(\beta) + \lambda \|\beta\|_1 \quad \Longleftrightarrow \quad \min_{\beta} \text{SSR}(\beta) \text{ s.a. } \|\beta\|_1 \leq c$$

La correspondencia $\lambda \leftrightarrow c$ es decreciente y depende de los datos: λ grande $\Longleftrightarrow$ c chico.

Intuición en una dimensión


Las dos piezas por separado



La pérdida sola: una parábola con vértice en β^{OLS} .

Intuición en una dimensión


Las dos piezas por separado



La penalidad: una V con el "kink" en cero. Ahí no hay derivada.

Intuición en una dimensión


Las dos piezas por separado



La suma $E(\beta)$: hereda el "kink".


Intuición en una dimensión

Subir λ




Intuición en una dimensión

Subir λ




Intuición en una dimensión

Subir λ



Intuición en una dimensión

Subir λ



Intuición en 1 Dimension


Solución analítica

$$\min_{\beta} E(\beta) = \sum_{i=1}^n (y_i - x_i \beta)^2 + \lambda |\beta| \quad (7)$$

Intuición en 1 Dimension

Solución analítica

$$\min_{\beta} E(\beta) = \sum_{i=1}^n (y_i - x_i \beta)^2 + \lambda |\beta| \quad (7)$$



Intuición en 1 Dimension

Solución analítica

$$\min_{\beta} E(\beta) = \sum_{i=1}^n (y_i - x_i \beta)^2 + \lambda |\beta| \quad (8)$$

Intuición en 1 Dimension

Solución analítica

$$\min_{\beta} E(\beta) = \sum_{i=1}^n (y_i - x_i \beta)^2 + \lambda |\beta| \quad (8)$$

$$E(\beta) = \begin{cases} \sum_{i=1}^n (y_i - x_i \beta)^2 + \lambda \beta, & \beta > 0, \\ \sum_{i=1}^n (y_i - x_i \beta)^2 - \lambda \beta, & \beta < 0. \end{cases} \quad (9)$$

Primero simplificamos la pérdida cuadrática

$$\sum_{i=1}^n (y_i - x_i \beta)^2 = \sum_{i=1}^n y_i^2 - 2\beta \sum_{i=1}^n x_i y_i + \beta^2 \sum_{i=1}^n x_i^2.$$

Usando las normas iguales a 1:

$$\sum_{i=1}^n (y_i - x_i \beta)^2 = 1 - 2\beta \sum_{i=1}^n x_i y_i + \beta^2.$$

Por tanto:

$$E(\beta) = 1 - 2\beta \sum_{i=1}^n x_i y_i + \beta^2 + \lambda |\beta|$$

$$\beta > 0$$

Si $\beta > 0$, entonces $|\beta| = \beta$.

$$E_+(\beta) = 1 - 2\beta \sum_{i=1}^n x_i y_i + \beta^2 + \lambda\beta.$$

Ahora sí podemos derivar normalmente:

$$E'_+(\beta) = -2 \sum_{i=1}^n x_i y_i + 2\beta + \lambda.$$

Condición de primer orden:

$$-2 \sum_{i=1}^n x_i y_i + 2\beta + \lambda = 0.$$

$$\beta > 0$$

De:

$$-2 \sum_{i=1}^n x_i y_i + 2\beta + \lambda = 0$$

obtenemos:

$$2\beta = 2 \sum_{i=1}^n x_i y_i - \lambda.$$

Por tanto:


$$\beta = \sum_{i=1}^n x_i y_i - \frac{\lambda}{2}.$$

Pero este brazo exige $\beta > 0$:

$$\sum_{i=1}^n x_i y_i > \frac{\lambda}{2}$$

$$\beta = 0$$

En $\beta = 0$, el valor absoluto tiene una esquina.



No hay una derivada única. Por eso usamos **subgradiientes**.

Subgradientes

Sea $f : \mathbb{R}^p \rightarrow \mathbb{R}$ convexa.

Un vector $g \in \mathbb{R}^p$ es un **subgradiente** de f en x si:

$$f(u) \geq f(x) + g'(u - x) \quad \text{para todo } u.$$


El conjunto de todos los subgradientes se llama **subdiferencial**:

$$\partial f(x)$$

Para $f(\beta) = |\beta|$:

$$\partial|\beta| = \begin{cases} \{1\}, & \beta > 0, \\ [-1, 1], & \beta = 0, \\ \{-1\}, & \beta < 0. \end{cases}$$

Subgradietes



$$\beta = 0$$

Aplicamos subgradiente

Recordemos:

$$E(\beta) = 1 - 2\beta \sum_{i=1}^n x_i y_i + \beta^2 + \lambda |\beta|.$$

La condición de óptimo con subgradiente es:

$$0 \in -2 \sum_{i=1}^n x_i y_i + 2\beta + \lambda \partial |\beta|.$$

En $\beta = 0$:

$$0 \in -2 \sum_{i=1}^n x_i y_i + \lambda [-1, 1].$$

Equivale a que exista $s \in [-1, 1]$ tal que:

$$0 = -2 \sum_{i=1}^n x_i y_i + \lambda s.$$

Cuándo $\hat{\beta} = 0$

De:

$$0 = -2 \sum_{i=1}^n x_i y_i + \lambda s, \quad s \in [-1, 1],$$

obtenemos:

$$2 \sum_{i=1}^n x_i y_i = \lambda s.$$

Como $|s| \leq 1$:

$$\left| 2 \sum_{i=1}^n x_i y_i \right| \leq \lambda.$$

Por tanto:

$$\left| \sum_{i=1}^n x_i y_i \right| \leq \frac{\lambda}{2}$$

Entonces $\hat{\beta} = 0$.

KKT

Queremos evitar el valor absoluto usando dos variables no negativas:

$$\beta = \beta^+ - \beta^-$$

con

$$\beta^+ \geq 0, \quad \beta^- \geq 0$$

$$\beta^+ = \max(\beta, 0), \quad \beta^- = \max(-\beta, 0).$$

podemos escribir el valor absoluto

$$|\beta| = \beta^+ + \beta^-.$$

KKT

Problema equivalente con β^+ y β^-

Como:

$$\beta = \beta^+ - \beta^-, \quad |\beta| = \beta^+ + \beta^-,$$

reescribimos:

$$\min_{\beta^+, \beta^-} \sum_{i=1}^n (y_i - x_i(\beta^+ - \beta^-))^2 + \lambda(\beta^+ + \beta^-)$$

$$\text{s.a.} \quad \beta^+ \geq 0, \quad \beta^- \geq 0.$$

Equivalente en forma estándar:

$$-\beta^+ \leq 0, \quad -\beta^- \leq 0.$$

KKT

Lagrangiano KKT

Con multiplicadores:

$$\mu_+ \geq 0, \quad \mu_- \geq 0,$$

formamos:

$$\mathcal{L} = \sum_{i=1}^n (y_i - x_i(\beta^+ - \beta^-))^2 + \lambda(\beta^+ + \beta^-) - \mu_+\beta^+ - \mu_-\beta^-.$$

Usando $\beta = \beta^+ - \beta^-$:

$$\sum_{i=1}^n (y_i - x_i\beta)^2 = 1 - 2\beta \sum_{i=1}^n x_i y_i + \beta^2.$$

KKT

Condiciones KKT

Derivando respecto a β^+ :

$$2\beta - 2 \sum_{i=1}^n x_i y_i + \lambda - \mu_+ = 0$$

Derivando respecto a β^- :

$$-2\beta + 2 \sum_{i=1}^n x_i y_i + \lambda - \mu_- = 0$$

Además:

$$\beta^+ \geq 0, \quad \beta^- \geq 0, \quad \mu_+ \geq 0, \quad \mu_- \geq 0.$$

Complementariedad:

$$\mu_+ \beta^+ = 0, \quad \mu_- \beta^- = 0$$

KKT

KKT en el brazo $\beta > 0$

Si $\beta > 0$, entonces:

$$\beta^+ > 0, \quad \beta^- = 0.$$

Por complementariedad:

$$\mu_+ = 0.$$

La primera condición KKT da:

$$2\beta - 2 \sum_{i=1}^n x_i y_i + \lambda = 0.$$

Luego:

$$\beta = \sum_{i=1}^n x_i y_i - \frac{\lambda}{2}$$

Y el brazo exige:

$$\sum_{i=1}^n x_i y_i > \frac{\lambda}{2}$$

KKT

KKT en el punto $\beta = 0$

Si $\beta = 0$, entonces:

$$\beta^+ = 0, \quad \beta^- = 0.$$

Las condiciones quedan:

$$-2 \sum_{i=1}^n x_i y_i + \lambda - \mu_+ = 0 \quad \Rightarrow \quad \mu_+ = \lambda - 2 \sum_{i=1}^n x_i y_i,$$

$$2 \sum_{i=1}^n x_i y_i + \lambda - \mu_- = 0 \quad \Rightarrow \quad \mu_- = \lambda + 2 \sum_{i=1}^n x_i y_i.$$

Como $\mu_+ \geq 0$ y $\mu_- \geq 0$:

$$\left| \sum_{i=1}^n x_i y_i \right| \leq \frac{\lambda}{2}$$

Generalizando

- **Diseño ortonormal** ($X'X = I$): el objetivo se **separa** coordenada por coordenada, y la solución es soft-thresholding aplicado a cada una.

$$\hat{\beta}_j^{lasso} = \text{sign}(\hat{\beta}_j^{OLS}) \left(\left| \hat{\beta}_j^{OLS} \right| - \frac{\lambda}{2} \right)_+, \quad j = 1, \dots, p$$

- El problema de p variables son p copias independientes del caso escalar que acabamos de resolver. **Nada nuevo que derivar.**

Generalizando

Se cualquier X

- ▶ La condición KKT, escrita en coeficientes:


$$\beta_j \neq 0 \implies \left| 2 x_j'(y - X\hat{\beta}) \right| = \lambda$$

$$\beta_j = 0 \implies \left| 2 x_j'(y - X\hat{\beta}) \right| \leq \lambda$$

- ▶ $x_j'(y - X\hat{\beta})$ es la correlación de la variable j con lo que el modelo **todavía no explica**.
- ▶ Las que están *dentro* la tienen clavada en λ ; las de *afuera*, por debajo. λ es el **precio de entrada**
- ▶ No hay forma cerrada, pero sí algoritmo: **coordinate descent**. Es lo que hace `glmnet`

Coordinate descent


Una coordenada por vez



Fijo β_2 y minimizo en β_1 : me muevo sobre la recta hasta que *toca* una curva de nivel. Eso es un problema en una dimensión.

Coordinate descent


Una coordenada por vez



Ahora al revés: fijo β_1 y minimizo en β_2 .


Coordinate descent

Una coordenada por vez




Coordinate descent

Cuando las X están correlacionadas




Coordinate descent

La correlación entre las X es clave




$\rho = 0.2$: tres pasos.



$\rho = 0.8$: sigue bajando.

Intuición en 2 Dimensiones (Lasso)

$$\min_{\beta} E(\beta) = \sum_{i=1}^n (y_i - x_{i1}\beta_1 - x_{i2}\beta_2)^2 \text{ s.a. } (|\beta_1| + |\beta_2|) \leq c \quad (10)$$



Ridge and Lasso: The good and the bad

- ▶ Objective 1: Accuracy
 - ▶ Minimize prediction error $\rightarrow$ Ridge, Lasso
- ▶ Objective 2: Dimensionality
 - ▶ Reduce the predictor space $\rightarrow$ Lasso's free lunch
- ▶ More predictors than observations ($p > n$)
 - ▶ OLS fails
 - ▶ Ridge augments data
 - ▶ Lasso chooses at most n variables

Ridge and Lasso: The good and the bad

OLS when $p > n$

- ▶ Rank? Max number of rows or columns that are linearly independent
 - ▶ Implies $\text{rank}(X_{n \times p}) \leq \min(k, n)$
- ▶ MCO we need $\text{rank}(X_{n \times p}) = k \implies k \leq n$
- ▶ If $\text{rank}(X_{n \times p}) = p$ then $\text{rank}(X'X) = k$
- ▶ If $p > n$, then $\text{rank}(X'X) \leq n < p$ then $(X'X)$ cannot be inverted
- ▶ Ridge works when $p \geq n$

Ridge and Lasso: The good and the bad

Ridge when $k > n$

$$\min_{\beta} E(\beta) = \sum_{i=1}^n (y_i - \sum_{j=1}^k x'_{ij} \beta_j)^2 + \lambda (\sum_{j=1}^k \beta_j)^2 \quad (11)$$

- ▶ Solution $\rightarrow$ data augmentation
- ▶ Intuition: Ridge “adds” p additional points.
- ▶ Allows us to “deal” with $p \geq n$

Ridge and Lasso: The good and the bad

Ridge when $p > n$

► Descomposición espectral

$X'X$ es simétrica y semidefinida positiva. Entonces siempre se puede escribir:


$$X'X = VDV' \quad V'V = VV' = I, \quad D = \text{diag}(d_1^2, \dots, d_p^2), \quad d_j^2 \geq 0$$

- Las columnas $v_1, \dots, v_p$ de V son direcciones ortogonales en el espacio de predictores: cada v_j es una combinación lineal de las X . Son los *eigenvectors*
- d_j^2 mide cuánta variación tienen los datos en la dirección v_j : $d_j^2 = \|Xv_j\|^2$. Son los *eigenvalues*

Ridge and Lasso: The good and the bad

- ▶ When we have a group of highly correlated variables,
 - ▶ Lasso chooses only one.

Ridge and Lasso: The good and the bad



Ridge and Lasso: The good and the bad

- ▶ When we have a group of highly correlated variables,
 - ▶ Lasso chooses only one. Makes it unstable for prediction.
 - ▶ Ridge shrinks the coefficients of correlated variables toward each other. This makes Ridge “work” better than Lasso. “Work” in terms of prediction error

Family of penalized regressions

$$\min_{\beta} R(\beta) = \sum_{i=1}^n (y_i - x_i' \beta)^2 + \lambda \sum_{s=2}^p |\beta_s|^q \quad (12)$$




FIGURE 3.12. *Contours of constant value of $\sum_j |\beta_j|^q$ for given values of q .*

Elastic net

$$\min_{\beta} EN(\beta) = \sum_{i=1}^n (y_i - \beta_0 - \sum_{j=1}^p x_{ij} \beta_j)^2 + \lambda \left(\alpha \sum_{j=1}^p |\beta_j| + \frac{(1-\alpha)}{2} \sum_{j=1}^p (\beta_j)^2 \right) \quad (13)$$

- Si $\alpha = 1$ Lasso
- Si $\alpha = 0$ Ridge

Elastic Net

- ▶ Elastic net: happy medium.
 - ▶ Good job at prediction and selecting variables

$$\min_{\beta} EN(\beta) = \sum_{i=1}^n (y_i - \beta_0 - \sum_{j=1}^p x_{ij} \beta_j)^2 + \lambda \left(\alpha \sum_{j=1}^p |\beta_j| + \frac{(1-\alpha)}{2} \sum_{j=1}^p (\beta_j)^2 \right) \quad (14)$$

- ▶ Mixes Ridge and Lasso
- ▶ Lasso selects predictors
- ▶ Strict convexity part of the penalty (ridge) solves the grouping instability problem
- ▶ How to choose (λ, α) ? → Bidimensional Crossvalidation
- ▶ Recommended lecture: Zou, H. & Hastie, T. (2005)